



Rapport de:

TP 1 : "Installation et configuration d'Apache Hadoop et exécution d'un programme MapReduce dans un cluster hadoop à nœud unique et à nœuds multiples."

Réalisé par :

→ Riali Mouad

→ Addi Kamal

encadré par :

→ Pr. D.Zaidouni

Table de matières :

- I. Installation et configuration d'un nœud unique d'Apache Hadoop
 3.2.1 .
 - 1. Création d'un utilisateur hduser
 - 2. Mise en place de la clé ssh
 - 3. Installation de JAVA 8
 - 4. Installation d'Apache Hadoop 3.2.1
 - 5. Configuration d'Apache Hadoop 3.2.1
- II. Exécution d'un programme Map/Reduce dans un cluster à nœud unique .
- III. Configuration d'un cluster multi-noeuds d'Apache Hadoop .
 - 1. Attribution statique d'adresse IP à la machine hadoopmaster
 - 2. Modification des fichiers de configuration de hadoop
 - 3. Clonage de la machine hadoopmaster
 - 4. Modification à faire dans les machines slave1 et slave2
 - 5. Connexion entre les machines du cluster
- IV. Exécution d'un programme Map/Reduce dans un cluster multinoeuds .











Pré-requis techniques :

x Oracle AM VirtualBox-6.0 :

Oracle VM VirtualBox (anciennement VirtualBox) est un logiciel libre de virtualisation publié par Oracle.

Lien de Téléchargement :



https://download.virtualbox.org/virtualbox/6.0.12/virtualbox-6.0_6.0.12-133076~Ubuntu~bionic_amd64.ddeb

x Ubuntu 18.04.3 :

Ubuntu est un système d'exploitation GNU/Linux basé sur la distribution Linux Debian. Il est développé, commercialisé et maintenu pour les ordinateurs individuels (desktop), les serveurs (Server) et les objets connectés (Core) par la société Canonical.



Lien de Téléchargement de la version Ubuntu 20.04 :

https://ubuntu.com/download/desktop/thank-you? version=20.04.1&architecture=amd64

x Apache Hadoop version=3.2.1 :

est un framework libre et open source écrit en Java destiné à faciliter la création d'applications distribuées et échelonnables permettant aux applications de travailler avec des milliers de nœuds et des pétaoctets de données.



Ainsi chaque nœud est

constitué de machines standard regroupées en grappe.

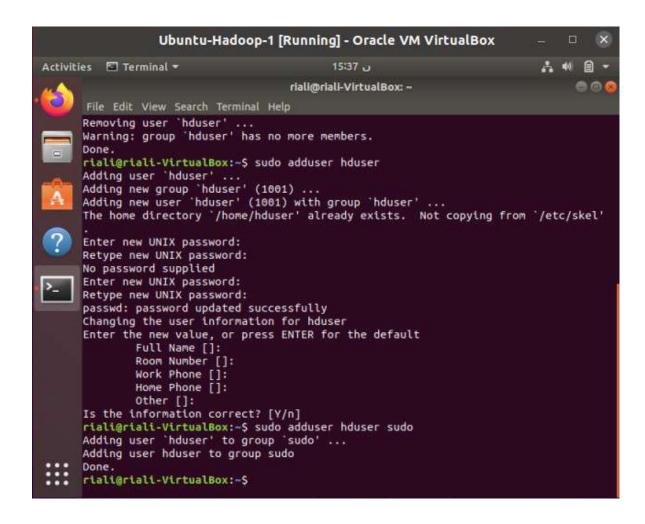
Lien de Téléchargement :

https://downloads.apache.org/hadoop/common/hadoop-3.2.1/hadoop-3.2.1.tar.qz

pour Java 8 : https://github.com/sanyoushi/java-buildpack.git

I. Installation et configuration d'un nœud unique d'Apache Hadoop 3.2.1

Création d'un utilisateur hduser:



- Pour ajouter un nouveau "user" qu'on va l'appeler "hduser", il faut juste appeler la commande suivante : sudo adduser hduser
- Ensuite on va appeler la commande : sudo adduser hduser sudo pour inclure le nouveau user dans le groupe sudo pour faire de lui un sudoer dont l'objectif est de lui permettre à exécuter des commandes en tant que super utilisateur .

Mise en place de la clé ssh :

En premier lieu, il faut qu'on se connecte par l'utilisateur : hduser



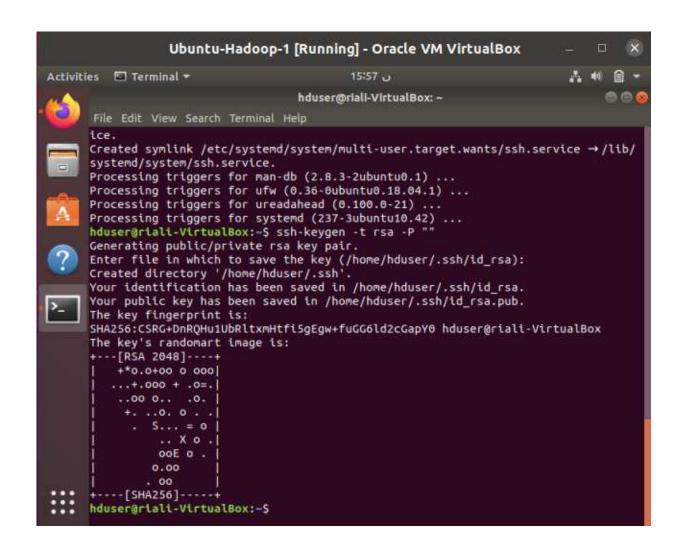
Installer le serveur openssh :

Sur Ubuntu 18.04, pour installer le serveur openssh, il ne faut qu'appeler la commande suivante : sudo apt-get install openssh-server

Mettre en place la clé ssh pour son propre compte :

Dans cette étape, on va comprendre pourquoi on doit se connecter par hduser, tout simplement, car il faut mettre en place une clé ssh pour celui-ci, pour qu'il puisse dans ce qui suit, se connecter aux autres machines de cluster qui vont être clonées à partir de cette machine-là, alors il faut taper ces commandes-là : ssh-keygen -t rsa - P ""

- cat ~/.ssh/id_rsa.pub >> ~/.ssh/authorized_keys
- chmod 0600 ~/.ssh/authorized keys



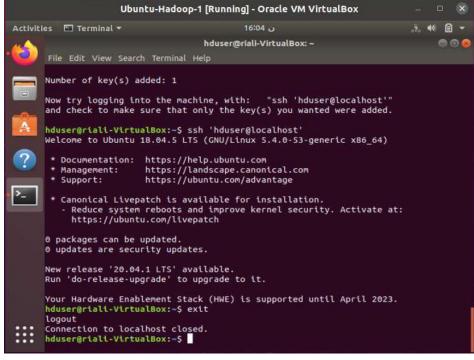
Copier la clé publique sur le serveur localhost :

Après la mise e place de la clé ssh pou le compte hduser, c'est le moment pour copier la clé publique sur le serveur localhost : ssh-copy-id -i /home/hduser/.ssh/id_rsa.pub hduser@localhost

Enfin on va tester la connexion a localhost par la commande suivante : ssh 'hduser@localhost'

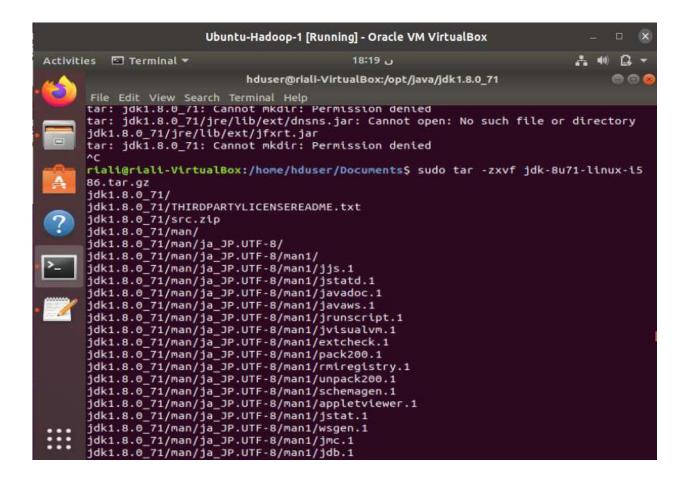
Installation de JAVA 8 :

Comme on a déjà
mentionné au début,
Hadoop est programmé
par java, alors il est
impérativement d'avoir
un JDK pour une bonne
configuration et un
bon fonctionnement de
Hadoop, alors dans ce
TP on a choisi
d'installer le JAVA
8, D'abord on va
télécharger jdk-8u71-



<u>linux-x64.tar.gz</u> et après on va suite les étapes suivantes : tar - zxvf jdk-8u71-linux-x64.tar.gz mv jdk1.8.0_71/ /opt/java/

ps : on a déjà créé le rep /opt/java



Après le déplacement du répertoire jdk1.8.0_71 vers opt/java, on va mettre à jour les liens par défaut de jdk, pour cela on va appeler les commandes suivantes dans le nouveau répertoire de java :

- update-alternatives --install /usr/bin/java java /opt/java/jdk1.8.0_71/bin/java 100
- update-alternatives --config java

et on va refaire la même chose pour javac :

- update-alternatives --install /usr/bin/javac javac /opt/java/ jdk1.8.0_71/bin/javac 100
- update-alternatives -config javac

 sudo nano OU sudo vim OU sudo gedit /etc/profile , pour pouvoir modifier le fichier et ajouter ces trois lignes vers sa fin :

export JAVA_HOME=/opt/java/jdk1.8.0_71/
export JRE_HOME=/opt/java/jdk1.8.0._71/jre
export
PATH=\$PATH:/opt/java/jdk1.8.0_71/bin:/opt/java/jdk1.8.0_71/jre/
bin

- refaire les mêmes opérations pour le fichier : ~/.bashrc
- Exécuter les 2 commandes suivantes : source /etc/profile ET source ~/.bashrc

ET VOILA →on observe que le variable \$PATH nous donne le vrai

```
riali@riali-VirtualBox:/opt/java/jdk1.8.0_71$ nano /etc/profile riali@riali-VirtualBox:/opt/java/jdk1.8.0_71$ sudo nano /etc/profile riali@riali-VirtualBox:/opt/java/jdk1.8.0_71$ source /etc/profile riali@riali-VirtualBox:/opt/java/jdk1.8.0_71$ su hduser Password:

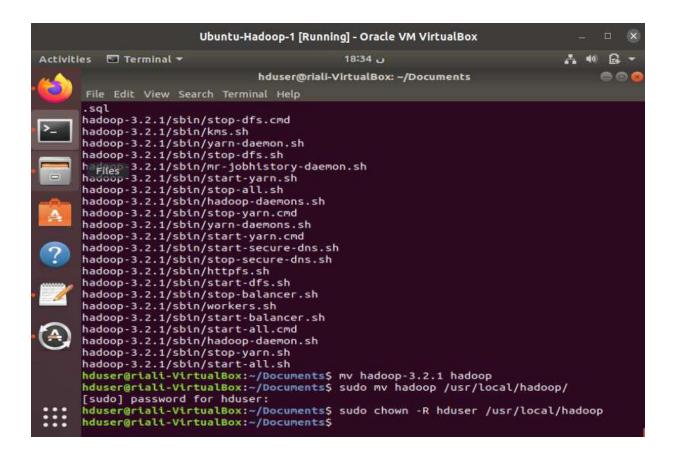
hduser@riali-VirtualBox:/opt/java/jdk1.8.0_71$ source /etc/profile hduser@riali-VirtualBox:/opt/java/jdk1.8.0_71$ sudo nano ~/.bashrc [sudo] password for hduser:

hduser@riali-VirtualBox:/opt/java/jdk1.8.0_71$ echo $PATH /usr/local/sbin:/usr/local/bin:/usr/sbin:/usr/bin:/bin:/usr/games:/usr/local/games:/snap/bin:/opt/java/jdk1.8.0_71/bin:/opt/java/jdk1.8.0_71/jre/bin hduser@riali-VirtualBox:/opt/java/jdk1.8.0_71$
```

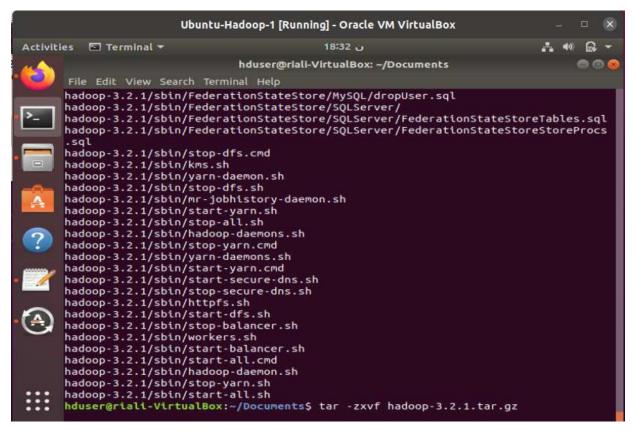
chemin vers JAVA 8

Installation d'Apache Hadoop 3.2.1

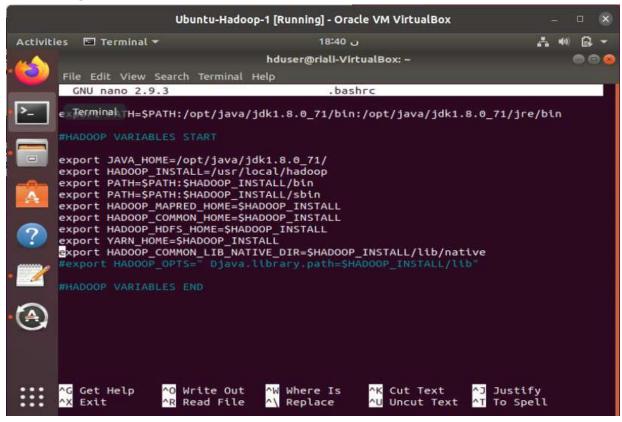
On va imiter les étapes faites pour Java 8 , sauf qu'on va déplacer le répertoire vers : "/usr/local/" **On aura alors :**



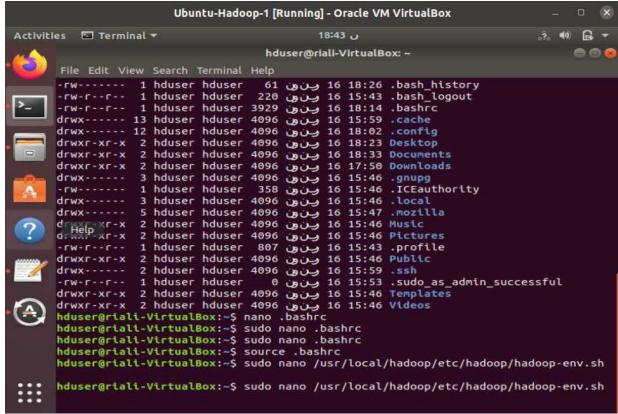
la ligne : "sudo chown -R hduser /usr/local/hadoop" donne le droit a hduser d'opérer sur les fichiers et répertoires inclus dans /usr/local/hadoop de manière récursive.récursive.



Ainsi, il faut modifier les fichiers ".bashrc" et "/etc/profile" et ajouter les chemins vers \$HADOOP_HOMEetc, comme il est clair dans l'image au-dessous :



, on ouvre le fichier /usr/local/hadoop/etc/hadoop/hadoop-env.sh et on modifie la variable d'environnement JAVA_HOME : export

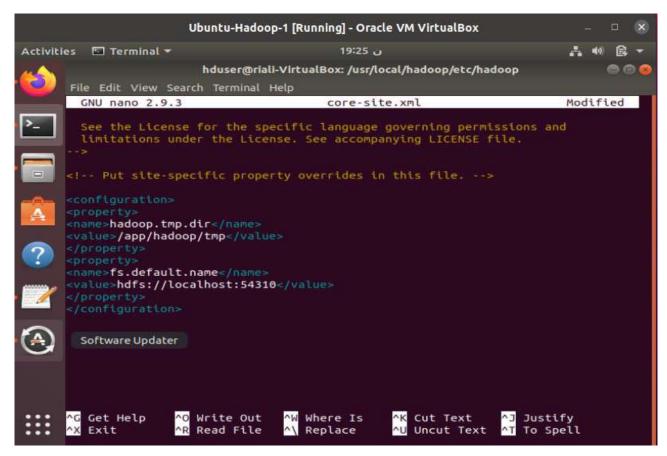


JAVA_HOME=/opt/java/jdk1.8.0_71

On crée le répertoire des fichiers temporaires de hadoop :

- sudo mkdir -p /app/hadoop/tmp
- sudo chown hduser /app/hadoop/tmp

Modification des fichiers de configuration de Hadoop :



Nous allons maintenant passer au répertoire «/ usr / local / hadoop» Commençons avec "core-site.xml":

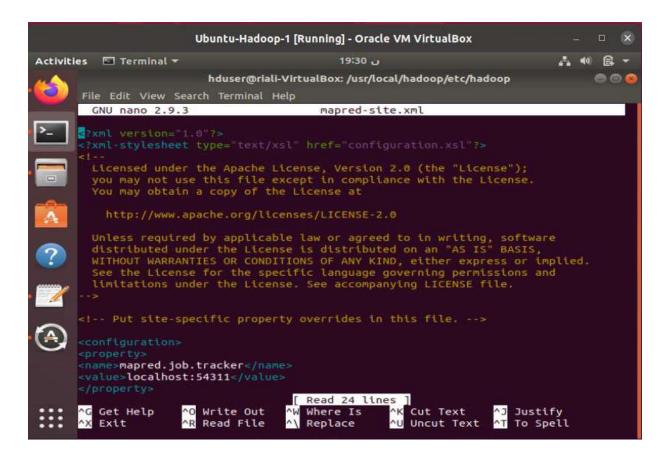
- hadoop.tmp.dir : C'est une base locale pour des répertoires temporaires.
- fs.default.name : Le nom du système de fichiers par défaut.défaut. Un URI dont le schéma et l'autorité déterminent l'implémentation FileSystem

Puis on va passer au "hdfs-site.xml" :

 dfs.replication: Lorsque nous stockons les fichiers dans HDFS, la structure hadoop divise le fichier en un ensemble de blocs (64 Mo ou 128 Mo), puis ces blocs seront répliqués sur les nœuds du cluster. La configuration dfs. la

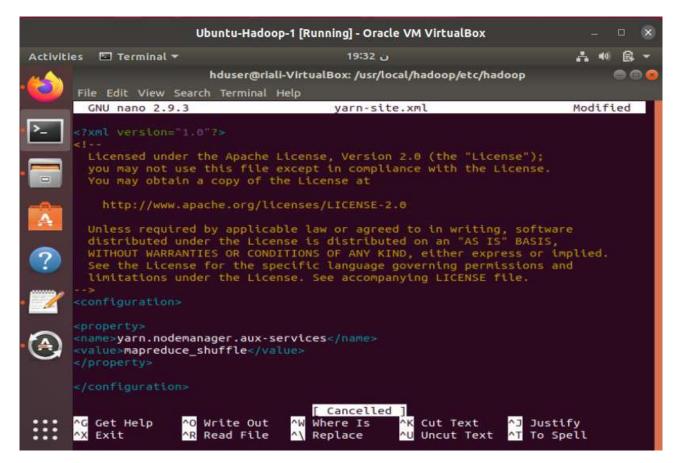
- réplication consiste à spécifier le nombre de réplications requises.
- dfs.namenode.name.dir: Détermine où sur le système de fichiers local le nœud de nom DFS doit stocker la table de noms (fsimage). S'il s'agit d'une liste de répertoires séparés par des virgules, la table de noms est répliquée dans tous les répertoires, pour la redondance.
- Dfs.datanode.data.dir: Détermine où sur le système de fichiers local un nœud de données DFS doit stocker ses blocs. S'il s'agit d'une liste de répertoires séparés par des virgules, les données seront stockées dans tous les répertoires nommés, généralement sur différents appareils. Les répertoires qui n'existent pas sont ignorés.

→ mapred-site.xml :



 mapred.job.tracker: L'hôte et le port sur lesquels s'exécute le suivi des travaux MapReduce. Si « local », les travaux sont exécutés en cours de processus comme une seule carte et réduisent la tâche.

→ yarn-site.xml :

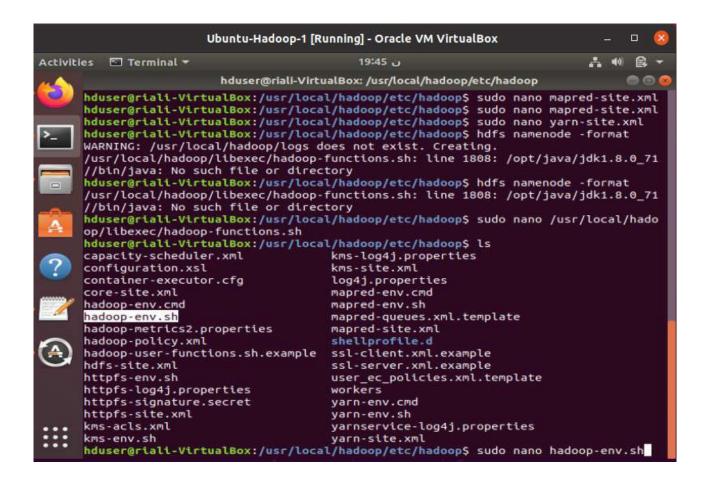


• yarn.nodemanager.aux-services : Le nom du service auxiliaire

Formatage du Namenode :

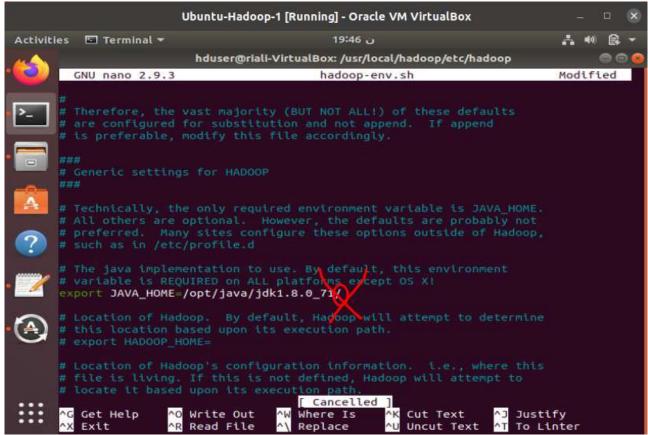
Pour pouvoir lancer le service **Hadoop Distributed File System** , il faut d'abord formatter le **Namenode** par la commande suivante :

"hdfs namenode -format" comme il est clair au-dessous :

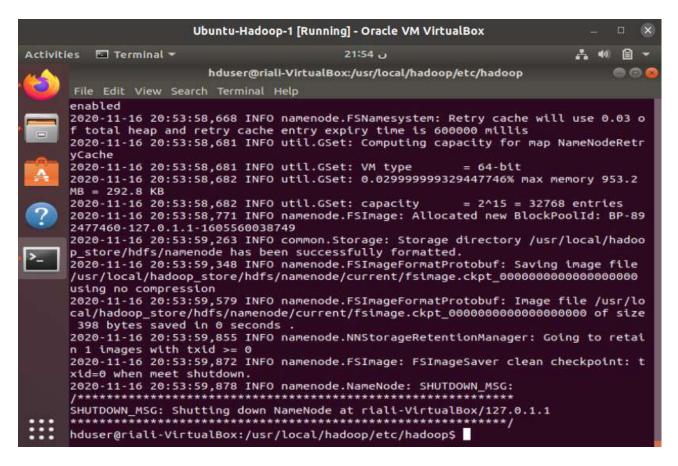


Malheureusement une erreur est survenue et voir le message d'erreur on peut bien estimer qu'il faut modifier le variable JAVA_HOME dans le fichier hadoop-env.sh :

Après avoir changé le variable JAVA_HOME on peut d'abord relancer



notre commande du formatage du Namenode :

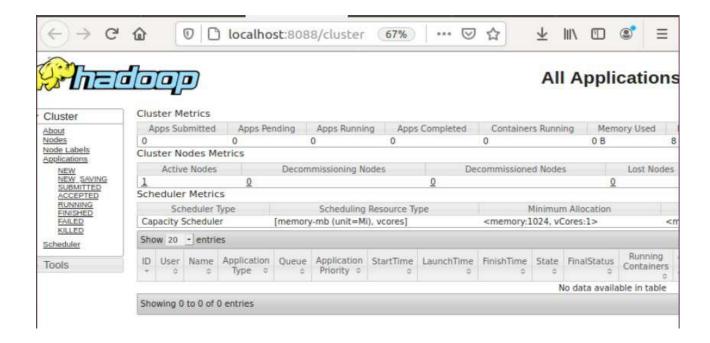


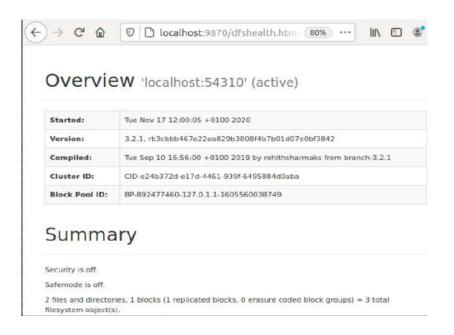
- Ensuite, on va lancer les deux commandes suivantes :
 - start-dfs.sh : Démarre les démons Hadoop DFS, le namenode et les datanodes
 - start-yarn.sh : démarre le serveur MapReduce
 - **jps** : Pour s'assurer que tout fonctionne, utiliser l'outil jps pour lister les processus Java en cours d'exécution

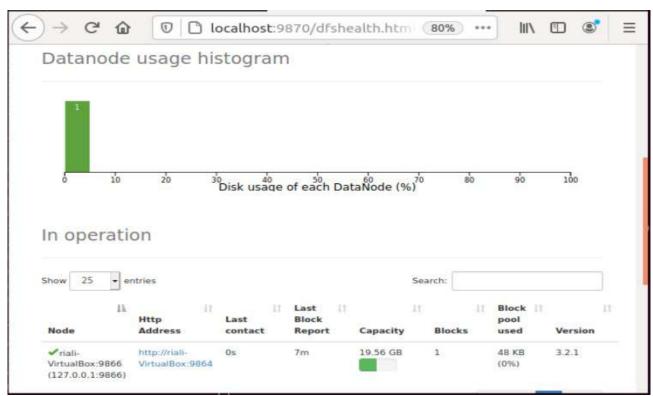
```
hduser@riali-VirtualBox:/usr/local/hadoop/etc/hadoop$ start-dfs.sh
Starting namenodes on [localhost]
localhost: namenode is running as process 2939. Stop it first.
Starting datamodes
localhost: datanode is running as process 3101.
Starting secondary namenodes [riali-VirtualBox]
                                                          Stop it first.
riali-VirtualBox: secondarynamenode is running as process 3300. Stop it first.
2020-11-16 21:57:02,379 WARN util.NativeCodeLoader: Unable to load native-hadoo
p library for your platform... using builtin-java classes where applicable hduser@riali-VirtualBox:/usr/local/hadoop/etc/hadoop$ start-yarn.sh
Starting resourcemanager
Starting nodemanagers
hduser@riali-VirtualBox:/usr/local/hadoop/etc/hadoop$ jps
3300 SecondaryNameNode
5275 Jps
2939 NameNode
4924 NodeManager
3101 DataNode
4767 ResourceManager
```

II. Exécution d'un programme Map/Reduce dans un cluster à nœud unique :

Accéder aux services de Hadoop via le navigateur :







Exécution d'un programme Map/Reduce :

Pour exécuter le programme Map/Reduce, on va exécuter les commandes suivantes :

• hdfs dfsadmin -report : "pour tester le bon fonctionnement du service hdfs"

```
Live datanodes (1):
Name: 127.0.0.1:9866 (localhost)
Hostname: riali-VirtualBox
Decommission Status : Normal
Configured Capacity: 21001486336 (19.56 GB)
DFS Used: 28672 (28 KB)
Non DFS Used: 9721094144 (9.05 GB)
DFS Remaining: 10189950976 (9.49 GB)
DFS Used%: 0.00%
DFS Remaining%: 48.52%
Configured Cache Capacity: 0 (0 B)
Cache Used: 0 (0 B)
Cache Remaining: 0 (0 B)
Cache Used%: 100.00%
Cache Remaining%: 0.00%
Xceivers: 1
Last contact: Mon Nov 16 23:04:40 WET 2020
Last Block Report: Mon Nov 16 23:02:13 WET 2020
Num of Blocks: 0
hduser@riali-VirtualBox:/usr/local/hadoop/etc/hadoop$
```

- cd /home/hduser/Documents/code/ : accéder au répertoire contenant les fichiers wordcount et le fichier poeme.txt
- mkdir -p org/hadoop/wordcount/ : créer les répertoires org ET hadoop ET wordcount
- . classpath : exécuter le fichier "classpath"
- javac WCount*java : exécuter tous les fichiers {Wcount*java}
- mv *.class org/hadoop/wordcount/
- jar -cvf wcount.jar . /home/hduser/Documents/code/org : Générer le .jar

```
File Edit View Search Terminal Help
  symbol:
            class Text
  location: class WCountReduce
46 errors
hduser@riali-VirtualBox:~/Documents/code$ . classpath
hduser@riali-VirtualBox:~/Documents/code$ javac WCount*java
hduser@riali-VirtualBox:~/Documents/code$ mv *.class org/hadoop/wordcount/
hduser@riali-VirtualBox:~/Documents/code$ jar -cvf wcount.jar . /home/hduser/Do
cuments/code/org
added manifest
adding: classpath(in = 305) (out= 114)(deflated 62%)
adding: org/(in = 0) (out= 0)(stored 0%)
adding: org/hadoop/(in = 0) (out= 0)(stored 0%)
adding: org/hadoop/wordcount/(in = 0) (out= 0)(stored 0%)
adding: org/hadoop/wordcount/WCountReduce.class(in = 1834) (out= 775)(deflated
adding: org/hadoop/wordcount/WCountMap.class(in = 1674) (out= 722)(deflated 56%
adding: org/hadoop/wordcount/WCount.class(in = 1646) (out= 859)(deflated 47%)
adding: WCountMap.java(in = 1057) (out= 565)(deflated 46%)
adding: WCount.java(in = 2005) (out= 890)(deflated 55%)
adding: WCountReduce.java(in = 1142) (out= 589)(deflated 48%)
adding: home/hduser/Documents/code/org/(in = 0) (out= 0)(stored 0%)
adding: home/hduser/Documents/code/org/hadoop/(in = 0) (out= 0)(stored 0%)
adding: home/hduser/Documents/code/org/hadoop/wordcount/(in = 0) (out= 0)(store
d 0%)
adding: home/hduser/Documents/code/org/hadoop/wordcount/WCountReduce.class(in =
1834) (out= 775)(deflated 57%)
adding: home/hduser/Documents/code/org/hadoop/wordcount/WCountMap.class(in = 16
74) (out= 722)(deflated 56%)
```

- cd /usr/local/hadoop/ : accéder au répertoire de hadoop
- bin/hdfs dfs -put /home/hduser/Documents/code/poeme.txt / :
 Copier "poeme.txt" de fichiers local vers le système de
 fichiers de destination. Lit également l'entrée de stdin et
 écrit dans le système de fichiers de destination.
- bin/hdfs dfs -ls / : Pour un répertoire comme notre cas, il renvoie la liste de ses enfants directs comme dans Unix
- cd /home/hduser/Documents/code/
- hadoop jar wcount.jar org.hadoop.wordcount.WCount /poeme.txt /results

```
hduser@riali-VirtualBox:~/Documents/code$ cd /usr/local/hadoop/
hduser@riali-VirtualBox:/usr/local/hadoop$ bin/hdfs dfs -put /home/hduser/Docum
ents/code/poeme.txt /
2020-11-17 11:39:54,447 WARN util.NativeCodeLoader: Unable to load native-hadoo
p library for your platform... using builtin-java classes where applicable
put: `/home/hduser/Documents/code/poeme.txt': No such file or directory
hduser@riali-VirtualBox:/usr/local/hadoop$ bin/hdfs dfs -put /home/hduser/Docum
ents/code/poeme.txt /
2020-11-17 11:40:51,377 WARN util.NativeCodeLoader: Unable to load native-hadoo
p library for your platform... using builtin-java classes where applicable
put: `/poeme.txt': File exists
hduser@riali-VirtualBox:/usr/local/hadoop$ bin/hdfs dfs -ls /
2020-11-17 11:41:23.131 WARN util.NativeCodeLoader: Unable to load native-hadoo
p library for your platform... using builtin-java classes where applicable
Found 1 items
                                        1670 2020-11-17 00:11 /poeme.txt
- FW- F-- F--
             1 hduser supergroup
hduser@riali-VirtualBox:/usr/local/hadoop$ cd /home/hduser/Documents/code/
hduser@riali-VirtualBox:~/Documents/code$ hadoop jar wcount.jar org.hadoop.word
count.WCount /poeme.txt /results
2020-11-17 11:42:48,083 WARN util.NativeCodeLoader: Unable to load native-hadoo
p library for your platform... using builtin-java classes where applicable
2020-11-17 11:42:49,654 INFO impl.MetricsConfig: Loaded properties from hadoop-
metrics2.properties
2020-11-17 11:42:50,836 INFO impl.MetricsSystemImpl: Scheduled Metric snapshot
period at 10 second(s).
2020-11-17 11:42:50,836 INFO impl.MetricsSystemImpl: JobTracker metrics system
started
```

- hadoop fs -ls /results
- hadoop fs -cat /results/part-r-00000

```
hduser@riali-VirtualBox:~/Documents/code$ hadoop fs -ls /results
2020-11-17 11:43:38,675 WARN util.NativeCodeLoader: Unable to load native-hadoo
p library for your platform... using builtin-java classes where applicable
Found 2 items
-rw-r--r-- 1 hduser supergroup
                                        0 2020-11-17 11:42 /results/_SUCCESS 2823 2020-11-17 11:42 /results/part-r-00
- FW- F-- F--
             1 hduser supergroup
000
hduser@riali-VirtualBox:~/Documents/code$ hadoop fs -cat /results/part-r-00000
2020-11-17 11:44:24,582 WARN util.NativeCodeLoader: Unable to load native-hadoo
p library for your platform... using builtin-java classes where applicable
2020-11-17 11:44:26,078 INFO sasl.SaslDataTransferClient: SASL encryption trust
check: localHostTrusted = false, remoteHostTrusted = false
        6 occurences.
adoratent
                1 occurences.
ailes
       1 occurences.
        1 occurences.
aima
amour
        1 occurences.
        11 occurences.
au
bas
        1 occurences.
belle
        1 occurences.
bles
        1 occurences.
bras
        1 occurences.
bretagne
                1 occurences.
       1 occurences.
brula
celle
        1 occurences.
celui
        20 occurences.
cette
        1 occurences.
chancelle
               1 occurences.
```

III. Configuration d'un cluster multi-noeuds d'Apache Hadoop.

Attribution statique d'adresse IP à la machine hadoopmaster :

/etc/hosts

Modifier le fichier /etc/hosts de la machine en ajoutant les lignes suivantes qui représentent les IP fixes des différentes

- machines du cluster :
 - 192.168.0.1 hadoopmaster
 - 192.168.0.2 slave1
 - 192.168.0.3 slave2

```
GNU nano 2.9.3
                                         /etc/hosts
127.0.0.1
                 localhost
127.0.1.1
                 riali-VirtualBox
192.168.0.1
                 hadoopmaster
192.168.0.2
                 slave1
192.168.0.3
                 slave2
# The following lines are desirable for IPv6 capable hosts
::1    ip6-localhost ip6-loopback
fe00::0 ip6-localnet
ff00::0 ip6-mcastprefix
ff02::1 ip6-allnodes
ff02::2 ip6-allrouters
                        [ File '/etc/hosts' is unwritable ]
  Get Help
                   Write Out
                                    Where Is
                                                     Cut Text
                                                                   ^J Justify
                 ^R Read File
   Exit
                                    Replace
                                                     Uncut Text
```

/etc/network/interfaces :

Afin de configurer de manière permanente l'adresse IP fixe de la machine hadoopmaster, il faut ajouter les lignes suivantes dans /etc/network/interfaces :

```
auto enp0s3
iface enp0s3 inet static
address 192.168.0.1
netmask 255.255.255.0
gateway 192.168.0.254
```

```
riali@hadoopmaster: ~

File Edit View Search Terminal Help

GNU nano 2.9.3 /etc/network/interfaces

interfaces(5) file used by ifup(8) and ifdown(8)
auto lo
iface lo inet loopback
auto enp0s3
iface enp0s3 inet static
address 192.168.0.1
netmask 255.255.255.0
gateway 192.168.0.254
```

Pour prendre en compte ces configurations on doit redémarrer la machine :

sudo reboot

etc/hostname :

Modifier le contenu de ce fichier par : hadoopmaster



Modification des fichiers de configuration de hadoop :

hadoop_master :

Ensuite , il faut supprimer les fichiers dans **hadoop_master** et créer de nouveau le répertoire :

/usr/local/hadoop_master/hdfs/namenode exécuter les commandes suivantes :

- cd /usr/local/hadoop_store/
- sudo rm -rf *
- sudo mkdir -p /usr/local/hadoop_store/hdfs/namenode

chown -R hduser /usr/local/hadoop_store/

```
riali@hadoopmaster:~$ cd /usr/local/hadoop_store/
riali@hadoopmaster:/usr/local/hadoop_store$ ls
hdfs
riali@hadoopmaster:/usr/local/hadoop_store$ rm -rf *
rm: cannot remove 'hdfs/datanode': Permission denied
rm: cannot remove 'hdfs/namenode/current': Permission denied
riali@hadoopmaster:/usr/local/hadoop_store$ sudo rm -rf * [sudo] password for riali:
riali@hadoopmaster:/usr/local/hadoop_store$ ls
riali@hadoopmaster:/usr/local/hadoop_store$ mkdir -p /usr/local/hadoop_store/hd
fs/namenode
mkdir: cannot create directory '/usr/local/hadoop_store/hdfs': Permission denie
riali@hadoopmaster:/usr/local/hadoop_store$ sudo mkdir -p /usr/local/hadoop_sto
re/hdfs/namenode
riali@hadoopmaster:/usr/local/hadoop_store$ ls -R
hdfs
./hdfs:
namenode
./hdfs/namenode:
rtali@hadoopmaster:/usr/local/hadoop_store$
```

```
core-site.xml : [$ cd /usr/local/hadoop/etc/hadoop/]
```

```
GNU nano 2.9.3
                                          core-site.xml
 See the License for the specific language governing permissions and limitations under the License. See accompanying LICENSE file.
<!-- Put site-specific property overrides in this file. -->
<name>hadoop.tmp.dir</name>
<value>/app/hadoop/tmp</value>
<name>fs.default.name</name>
<value>hdfs://hadoopmaster:54310</value>
                                                                       ^]
^T
^G Get Help
                  ^O Write Out
                                   ^W Where Is
                                                        Cut Text
                                                                          Justify
                 ^R Read File
  Exit
                                      Replace
                                                        Uncut Text
                                                                          To Spell
```

hdfs-site.xml:

Modifier le fichier hdfs-site.xml, en modifiant la balise <configuration></configuration> →

```
<configuration>
<configuration>
<name>dfs.replication</name>
<value>2</value>
</property>
<name>dfs.namenode.name.dir</name>
<value>file:/usr/local/hadoop_store/hdfs/namenode</value>
```

</action="1">
</action="1

```
</configuration>
```

```
See the License for the specific language governing permitmentations under the License. See accompanying LICENSE
-->
<!-- Put site-specific property overrides in this file. --
<configuration>

<p
```

mapred-site.xml : On va manipuler ce fichier comme ceux-ci au-dessus : yarn-site.xml :

masters:

Créer le fichier masters qui contient le hostname de la machine masters :

- cd /usr/local/hadoop/etc/hadoop
- sudo nano masters



workers:

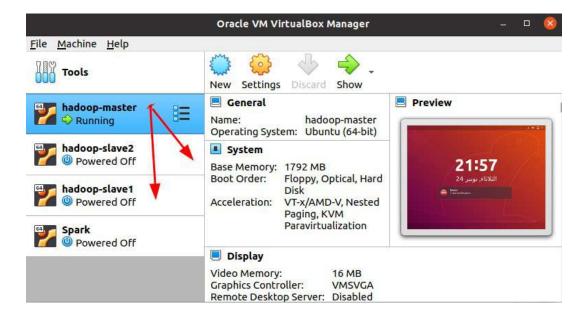
- cd /usr/local/hadoop/etc/hadoop
- sudo nano workers



Clonage de la machine hadoopmaster :

Nous allons cloner deux machines slave1 et slave2 à partir de la machine hadoopmaster, pour cela on va effectuer les étapes suivantes :

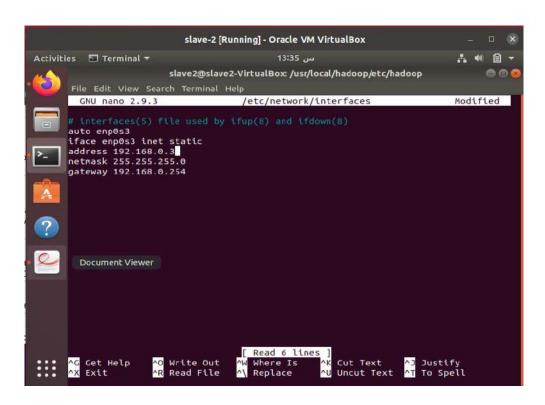
- Éteindre la machine hadoopmaster
- Bouton droit sur l'icône de la machine dans le gestionnaire virtualBox, puis cloner.
- Entrer le nom de la machine puis suivant.
- Choisir le type de clonage : clone intégral. [full]

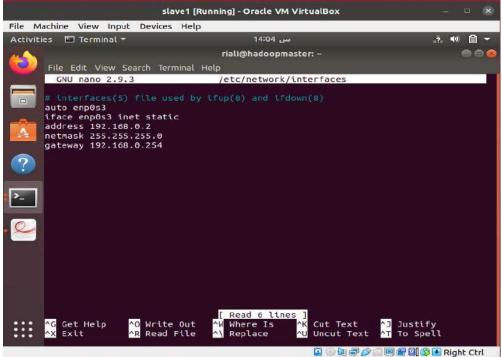


Configuration d'adresse IP fixe et de hostname :

Par modifier le fichier /etc/hostname pour chacune des 2 machines slaves, en définissant deux nouveaux hostnames qui sont : slave1 → hadoop-slave1 ET slave2 → hadoop-slave2, puis, on modefie les fichiers/etc/hosts /etc/network/interfaces, pour chacune des machines afin de leurs donner des adresses IP fixes :

```
GNU nano 2.9.3
                                      /etc/hosts
127.0.0.1
                localhost
127.0.1.1
                slave1
auto enp0s3
iface enp0s3 inet static
address 192.168.0.2
netmask 255.255.255.0
gateway 192.168.0.254
        ip6-localhost ip6-loopback
fe00::0 ip6-localnet
ff00::0 ip6-mcastprefix
ff02::1 ip6-allnodes
ff02::2 ip6-allrouters
```





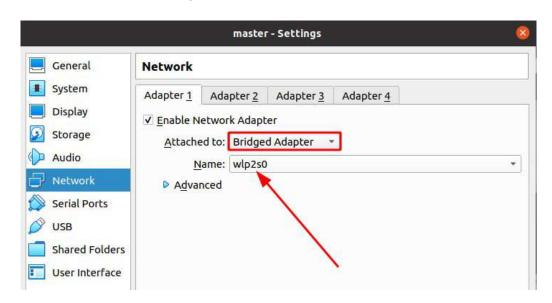
Ps : Pour prendre en compte les modifications, il faut redémarrer les deux machines slave1 et slave2: \$ sudo reboot

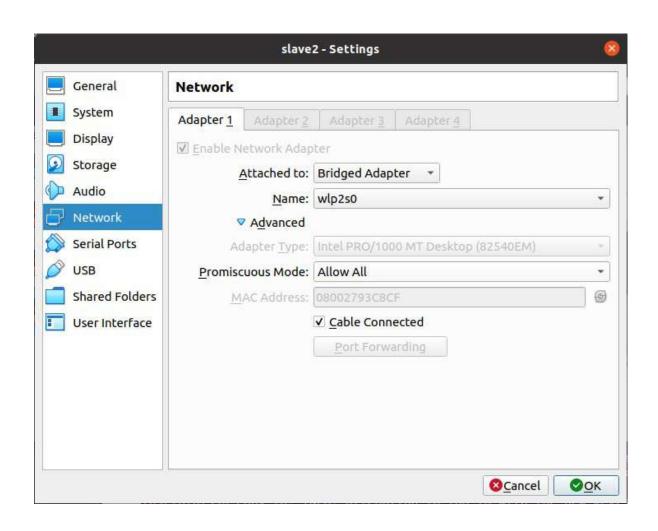
Dans la machine slave1 et slave2, supprimer les fichiers du répertoire de stockage de données créer par l'installation single node de Hadoop :

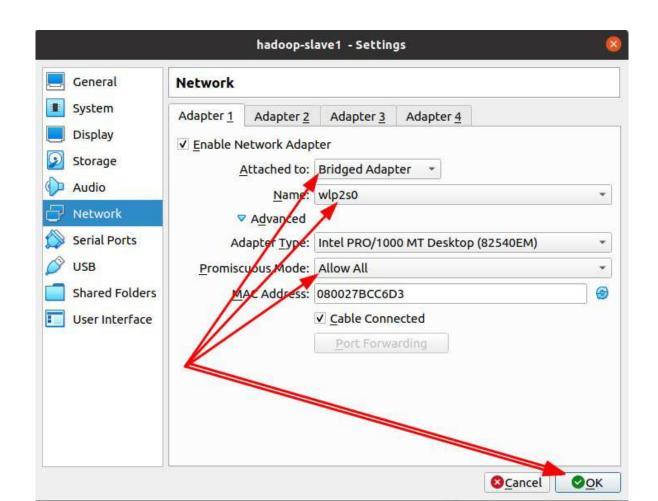
```
riali@slave2: /usr/local/hadoop_store
File Edit View Search Terminal Help
riali@slave2:~$ cd
riali@slave2:~$ cd /usr/local/hadoop_store/
riali@slave2:/usr/local/hadoop_store$ rm -rf *
rm: cannot remove 'hdfs/namenode': Permission denied
riali@slave2:/usr/local/hadoop_store$ sudo rm -rf *
[sudo] password for riali:
riali@slave2:/usr/local/hadoop_store$ mkdir -p /usr/local/hadoop_store/hdfs/dat
mkdir: cannot create directory '/usr/local/hadoop_store/hdfs': Permission denie
riali@slave2:/usr/local/hadoop_store$ sudo mkdir -p /usr/local/hadoop store/hdf
s/datanode
riali@slave2:/usr/local/hadoop_store$ chown -R hduser /usr/local/hadoop_store/h
dfs/datanode
chown: changing ownership of '/usr/local/hadoop_store/hdfs/datanode': Operation
not permitted
riali@slave2:/usr/local/hadoop_store$ sudo chown -R hduser /usr/local/hadoop st
ore/hdfs/datanode
riali@slave2:/usr/local/hadoop_store$
```

Connexion entre les machines du cluster :

établir un réseau ponté entre les machines virtuelles :







On va tester la connexion entre les machines du cluster en effectuant des pings entre les différentes machines.

Dans notre cas tout va bien !!!

```
AA
                                                                                          hduser@hadoopmaster: ~
    File Edit View Search Terminal Help
  hduser@hadoopmaster:~$ ping 192.168.0.1
  PING 192.168.0.1 (192.168.0.1) 56(84) bytes of data.
   64 bytes from 192.168.0.1: icmp_seq=1 ttl=64 time=0.047 ms
  64 bytes from 192.168.0.1: icmp seq=2 ttl=64 time=0.063 ms
   ^C
    --- 192.168.0.1 ping statistics ---
  2 packets transmitted, 2 received, 0% packet loss, time 1001ms
rtt min/avg/max/mdev = 0.047/0.055/0.063/0.008 ms
  hduser@hadoopmaster:~$ ping 192.168.0.2

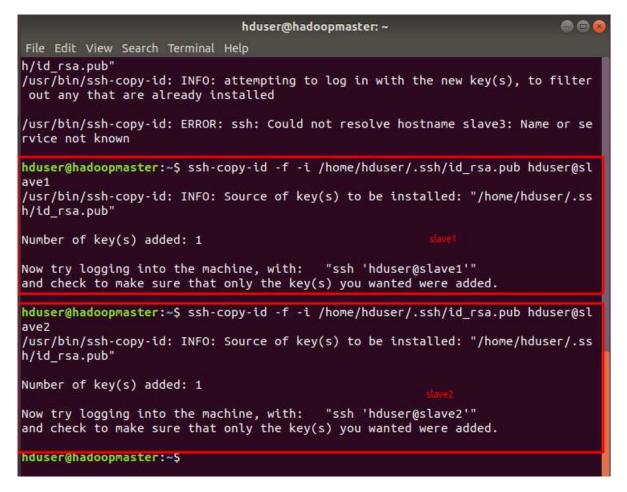
PING 192.168.0.2 (192.168.0.2) 56(84) bytes of data.

64 bytes from 192.168.0.2: icmp_seq=1 ttl=64 time=0.722 ms

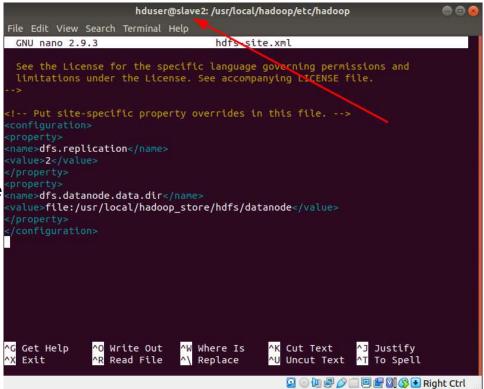
64 bytes from 192.168.0.2: icmp_seq=2 ttl=64 time=0.480 ms
   64 bytes from 192.168.0.2: icmp_seq=3 ttl=64 time=0.312 ms
    --- 192.168.0.2 ping statistics --
  3 packets transmitted, 3 received, 0% packet loss, time 2043ms
rtt min/avg/max/mdev = 0.312/0.504/0.722/0.170 ms
  hduser@hadoopmaster:~$ ping 192.168.0.
PING 192.168.0.3 (192.168.0.3) 56(84)
                                                                                                                                                                                                   riali@slave2: ~
                                                                                                                                                                                                                                                                                                   00
  64 bytes from 192.168.0.3: icmp_seq=1
64 bytes from 192.168.0.3: icmp_seq=2
                                                                                                                File Edit View Search Terminal Help
  64 bytes from 192.168.0.3: icmp_seq=2
64 bytes from 192.168.0.3: icmp_seq=2
64 bytes from 192.168.0.3: icmp_seq=3
64 bytes from 192.168.0.1 (192.168.0.1) 56(84) bytes of data.
64 bytes from 192.168.0.1: icmp_seq=1 ttl=64 time=0.979 ms
64 bytes from 192.168.0.1: icmp_seq=2 ttl=64 time=1.00 ms
64 bytes from 192.168.0.1: icmp_seq=3 ttl=64 time=0.936 ms
The second secon
  64 bytes from 192.168.0.1: icmp_seq=1 1^C
  64 bytes from 192.168.0.1: icmp_seq=2 --- 192.168.0.3 ping statistics ---
64 bytes from 192.168.0.1: icmp_seq=2 | 3 packets transmitted, 3 received, 0% packet loss, time 2041ms | rtt min/avg/max/mdev = 0.043/0.057/0.069/0.012 ms
                                                                                                                riali@slave2:~S
    --- 192.168.0.1 ping statistics ---
  3 packets transmitted, 3 received, 0% packet loss, time 2002ms rtt min/avg/max/mdev = 0.831/0.988/1.097/0.116 ms hduser@slave1:~$ ping 192.168.0.2 PING 192.168.0.2 (192.168.0.2) 56(84) bytes of data.
  64 bytes from 192.168.0.2: icmp_seq=1 ttl=64 time=0.048 ms
64 bytes from 192.168.0.2: icmp_seq=2 ttl=64 time=0.060 ms
64 bytes from 192.168.0.2: icmp_seq=3 ttl=64 time=0.066 ms
   ^C
    --- 192.168.0.2 ping statistics --
  3 packets transmitted, 3 received, 0% packet loss, time 2034ms rtt min/avg/max/mdev = 0.048/0.058/0.066/0.007 ms
  hduser@slave1:~$ ping 192.168.0.3
PING 192.168.0.3 (192.168.0.3) 56(84) bytes of data.
  64 bytes from 192.168.0.3: icmp_seq=1 ttl=64 time=0.727 ms
64 bytes from 192.168.0.3: icmp_seq=2 ttl=64 time=1.15 ms
  64 bytes from 192.168.0.3: icmp_seq=3 ttl=64 time=1.09 ms
   ^C
    --- 192.168.0.3 ping statistics ---
  3 packets transmitted, 3 received, 0% packet loss, time 2003ms
rtt min/avg/max/mdev = 0.727/0.990/1.153/0.191 ms
  hduser@slave1:~$
```

On va copier la clé ssh pour configurer un accès ssh sans mot de passe entre les machines du cluster.

- ssh-copy-id -i /home/hduser/.ssh/id_rsa.pub <u>hduser@slave1</u>
- ssh-copy-id -i /home/hduser/.ssh/id_rsa.pub <u>hduser@slave2</u>

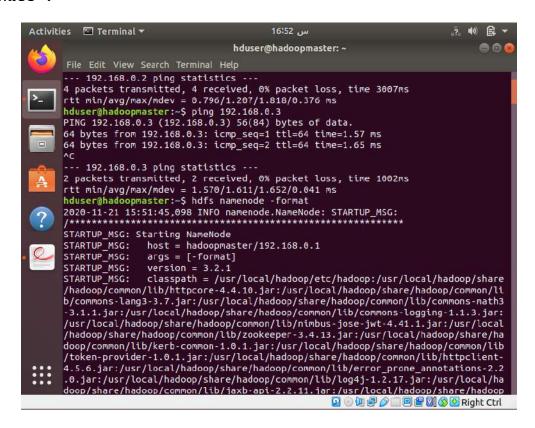


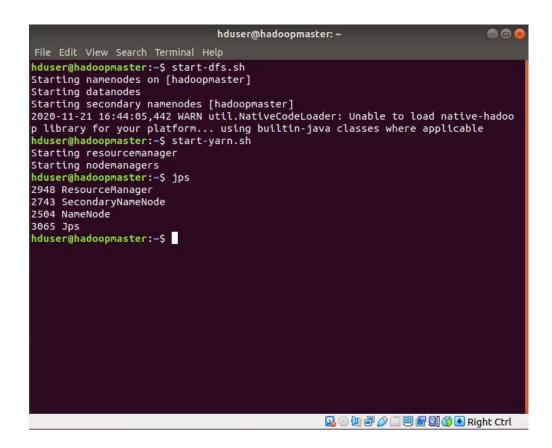
Ainsi, il faut modifier le fichier hdfs-site.xml de la machine virtuelle slave1 et slave2 comme suit :



Formater le namenode dans hadoopmaster :

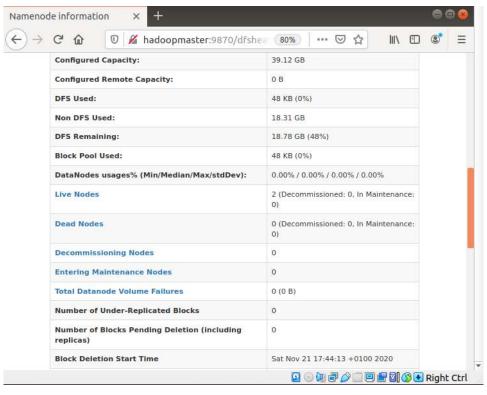
On va suivre les mêmes étapes et les commandes pour un unique nœud :

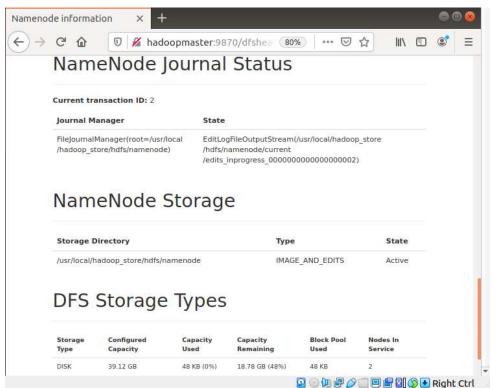


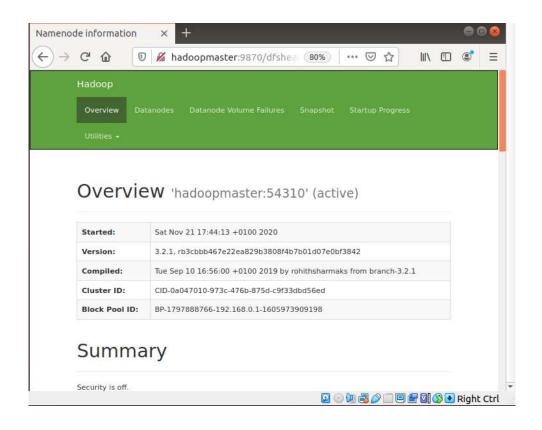


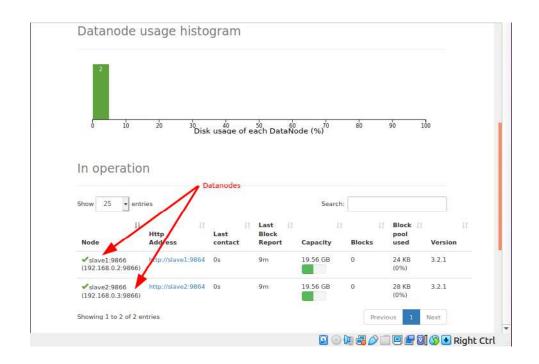
Accéder aux services de Hadoop via le navigateur :

http://hadoopmaster:9870/









IV. Exécution d'un programme Map/Reduce dans un cluster multi-noeuds :



Lancer la commande : « hdfs dfsadmin -report » pour vérifier le bon fonctionnement de tous les nœuds du cluster ou bien accéder aux services de Hadoop via le navigateur comme c'est le cas ici :

Configured Capacity:	39.12 GB
Configured Remote Capacity:	0 B
DFS Used:	48 KB (0%)
Non DFS Used:	18.31 GB
DFS Remaining:	18.78 GB (48%)
Block Pool Used:	48 KB (0%)
DataNodes usages% (Min/Median/Max/stdDev):	0.00% / 0.00% / 0.00% / 0.00%
Live Nodes	2 (Decommissioned: 0, In Maint 0)
Dead Nodes	0 (Decommissioned: 0, In Maint 0)
Decommissioning Nodes	0
Entering Maintenance Nodes	0
Total Datanode Volume Failures	0 (0 B)
Number of Under-Replicated Blocks	0

et on va suivre les mêmes étapes citées pour l'exécution d'un programme Map/Reduce pour un seul nœud :

```
س 18:45
Activities 🖸 Terminal 🕶
                                                                                                                     ? 🐠 🗎
                                          hduser@hadoopmaster: /usr/local/hadoop_store
          File Edit View Search Terminal Help
          ./hdfs/datanode:
          ./hdfs/namenode:
         hduser@hadoopmaster:/usr/local/hadoop_store$ chown R hduser
         chown: invalid user: ' R'
         hduser@hadoopmaster:/usr/local/hadoop_store$ chown -R hduser /usr/local/hadoop
         hduser@hadoopmaster:/usr/local/hadoop_store$ hdfs namenode -format
namenode is running as process 2504. Stop it first.
         hduser@hadoopmaster:/usr/local/hadoop_store$ kill 2504
         hduser@hadoopmaster:/usr/local/hadoop_store$ hdfs namenode -format 2020-11-21 17:44:25,030 INFO namenode.NameNode: STARTUP_MSG:
         STARTUP MSG: Starting NameNode
        STARTUP_MSG: host = hadoopmaster/192.168.0.1
STARTUP_MSG: args = [-format]
STARTUP_MSG: version = 3.2.1
         STARTUP_MSG: classpath = /usr/local/hadoop/etc/hadoop:/usr/local/hadoop/share
         /hadoop/common/lib/httpcore-4.4.10.jar:/usr/local/hadoop/share/hadoop/common/lib/commons-lang3-3.7.jar:/usr/local/hadoop/share/hadoop/common/lib/commons-math3-3.1.1.jar:/usr/local/hadoop/share/hadoop/common/lib/commons-logging-1.1.3.jar:
         /usr/local/hadoop/share/hadoop/common/lib/nimbus-jose-jwt-4.41.1.jar:/usr/local
         /hadoop/share/hadoop/common/lib/zookeeper-3.4.13.jar:/usr/local/hadoop/share/ha
         doop/common/lib/kerb-common-1.0.1.jar:/usr/local/hadoop/share/hadoop/common/lib/token-provider-1.0.1.jar:/usr/local/hadoop/share/hadoop/common/lib/httpclient-4.5.6.jar:/usr/local/hadoop/share/hadoop/common/lib/error_prone_annotations-2.2.0.jar:/usr/local/hadoop/share/hadoop/common/lib/log4j-1.2.17.jar:/usr/local/ha
```

```
hduser@hadoopmaster: /usr/local/hadoop
File Edit View Search Terminal Help
hduser@hadoopmaster:~/Documents/code$ jar -cvf wcount.jar . /home/hduser/Docume
nts/code/org
added manifest
adding: WCount.java(in = 2005) (out= 890)(deflated 55%)
adding: WCountMap.java(in = 1057) (out= 565)(deflated 46%)
adding: org/(in = 0) (out= 0)(stored 0%)
adding: org/hadoop/(in = 0) (out= 0)(stored 0%)
adding: org/hadoop/wordcount/(in = 0) (out= 0)(stored 0%)
adding: org/hadoop/wordcount/WCountMap.class(in = 1674) (out= 722)(deflated 56%
adding: org/hadoop/wordcount/WCountReduce.class(in = 1834) (out= 775)(deflated
adding: org/hadoop/wordcount/WCount.class(in = 1646) (out= 859)(deflated 47%)
adding: poeme.txt(in = 1670) (out= 611)(deflated 63%)
adding: classpath(in = 305) (out= 114)(deflated 62%)
adding: WCountReduce.java(in = 1142) (out= 589)(deflated 48%)
adding: home/hduser/Documents/code/org/(in = 0) (out= 0)(stored 0%)
adding: home/hduser/Documents/code/org/hadoop/(in = 0) (out= 0)(stored 0%)
adding: home/hduser/Documents/code/org/hadoop/wordcount/(in = 0) (out= 0)(store
d 0%)
adding: home/hduser/Documents/code/org/hadoop/wordcount/WCountMap.class(in = 16
74) (out= 722)(deflated 56%)
adding: home/hduser/Documents/code/org/hadoop/wordcount/WCountReduce.class(in =
1834) (out= 775)(deflated 57%)
adding: home/hduser/Documents/code/org/hadoop/wordcount/WCount.class(in = 1646)
(out= 859)(deflated 47%)
hduser@hadoopmaster:~/Documents/code$ cd /usr/local/hadoop/
hduser@hadoopmaster:/usr/local/hadoop$
```

```
adding: org/hadoop/(in = 0) (out= 0)(stored 0%)
adding: org/hadoop/wordcount/(in = 0) (out= 0)(stored 0%)
adding: org/hadoop/wordcount/WCountMap.class(in = 1674) (out= 722)(deflated 56%
adding: org/hadoop/wordcount/WCountReduce.class(in = 1834) (out= 775)(deflated
57%)
adding: org/hadoop/wordcount/WCount.class(in = 1646) (out= 859)(deflated 47%)
adding: poeme.txt(in = 1670) (out= 611)(deflated 63%)
adding: classpath(in = 305) (out= 114)(deflated 62%)
adding: WCountReduce.java(in = 1142) (out= 589)(deflated 48%)
adding: home/hduser/Documents/code/org/(in = 0) (out= 0)(stored 0%)
adding: home/hduser/Documents/code/org/hadoop/(in = 0) (out= 0)(stored 0%)
adding: home/hduser/Documents/code/org/hadoop/wordcount/(in = 0) (out= 0)(store
d 0%)
adding: home/hduser/Documents/code/org/hadoop/wordcount/WCountMap.class(in = 16
74) (out= 722)(deflated 56%)
adDocumentVieweruser/Documents/code/org/hadoop/wordcount/WCountReduce.class(in =
1834) (out= 775)(deflated 57%)
adding: home/hduser/Documents/code/org/hadoop/wordcount/WCount.class(in = 1646)
(out= 859)(deflated 47%)
hduser@hadoopmaster:~/Documents/code$ cd /usr/local/hadoop/
hduser@hadoopmaster:/usr/local/hadoop$ bin/hdfs dfs -put /home/hduser/Documents
/code/poeme.txt /
2020-11-22 23:02:23,397 WARN util.NativeCodeLoader: Unable to load native-hadoo
p library for your platform... using builtin-java classes where applicable
2020-11-22 23:02:28,235 INFO sasl.SaslDataTransferClient: SASL encryption trust
check: localHostTrusted = false, remoteHostTrusted = false
hduser@hadoopmaster:/usr/local/hadoop$
```

```
hduser@hadoopmaster:/usr/local/hadoop$ bin/hdfs dfs -ls /
2020-11-22 23:03:42,261 WARN util.NativeCodeLoader: Unable to load native-hadoo
p library for your platform... using builtin-java classes where applicable
Found 1 items
-rw-r---- 2 hduser supergroup 1670 2020-11-22 23:02 /poeme.txt
hduser@hadoopmaster:/usr/local/hadoop$
```

```
2020-11-22 23:05:08,880 INFO mapred.LocalJobRunner: Finishing task: attempt_loc al1315506290_0001_r_000000_0 2020-11-22 23:05:08,880 INFO mapred.LocalJobRunner: reduce task executor comple te. 2020-11-22 23:05:09,770 INFO mapreduce.Job: map 100% reduce 100% 2020-11-22 23:05:09,773 INFO mapreduce.Job: Job job_local1315506290_0001 comple ted successfully
```

```
hduser@hadoopmaster: ~/Documents/code
 File Edit View Search Terminal Help
sang 1
sanglots
                 1 occurences.
                        1 occurences.
1 occurences.
 sappelle
 se 1 occurences.
sentinelle 1 occurences.
 sentinette 1 occurences.
ses 1 occurences.
seul 1 occurences.
soldats 1 occurences.
songe 1 occurences.
sont 2 occurences.
eul
oldats
songe 1 occure
sons 2 occurences
sur 1 occurences.
sy 1 occurences
terre 1 occurences
tira 1 occurences
mbe 1 occurences
occurences
occurences
occurences
 trepas 1 occurences.
triste 1 occurences.
trompa 1 occurences.
un 4 occurences.
                 4 occurences.
1 occurences.
 verra
                  1 occurences.
 vie
 violoncelle
                                   1 occurences.
 vive
vivra
                  1 occurences.
1 occurences.
 hduser@hadoopmaster:~/Documents/code$
```

